

Relatório Técnico de Projeto

Detecção de Anomalias em Transações Bancárias com Python e Machine Learning

Autor: Willian Nunes dos Santos

Domínio: Ciência de Dados / Machine Learning

Dataset: Credit Card Fraud Detection (TensorFlow Storage)

Ferramentas: Python, Pandas, Scikit-Learn, XGBoost, SHAP

1. Visão Geral e Contexto do Problema

A detecção de fraudes em transações financeiras por cartão de crédito representa um dos maiores desafios no setor de tecnologia financeira (Fintech) e segurança bancária. A principal complexidade reside no forte **desbalanceamento de classes**: transações fraudulentas constituem uma fração minúscula do volume total de transações processadas diariamente, fazendo com que modelos preditivos tradicionais tendam a ignorar a classe minoritária em favor da acurácia global.

Este projeto desenvolve um pipeline preditivo completo de ponta a ponta (end-to-end), estruturado em Python, para identificar com alta precisão e sensibilidade transações anômalas, mitigando falsos negativos e garantindo interpretabilidade analítica.

2. Etapas Metodológicas do Pipeline

O desenvolvimento seguiu as melhores práticas de engenharia de dados e modelagem preditiva, compreendendo as seguintes fases:

- Análise Exploratória e Diagnóstico de Desbalanceamento:** Verificação estatística da distribuição da variável alvo (``Class``), confirmando a assimetria severa do conjunto de dados.
- Engenharia de Atributos (Feature Engineering):** Transformação da variável monetária bruta (``Amount``) através de logaritmo (``Amount_log``) para reduzir assimetria e aplicação de padronização (``StandardScaler``), além de divisão estratificada dos conjuntos de treino e teste.
- Modelagem Baseline (Regressão Logística):** Estabelecimento de uma linha de base estatística utilizando Regressão Logística, avaliada por métricas robustas para desbalanceamento: *Recall*, *Precision*, *F1-score*, Curva ROC (AUC) e Curva Precision-Recall.
- Estratégias de Balanceamento:** Avaliação comparativa de técnicas de reamostragem como *Undersampling* e *Oversampling* (SMOTE), bem com o ajuste de pesos nativos de classe (``class_weight`` e ``scale_pos_weight``).

3. Modelagem Avançada e Otimização

Para capturar relações não-lineares complexas inerentes a fraudes financeiras, o projeto evoluiu para algoritmos baseados em árvores de decisão e boosting:

- Random Forest:** Empregado com balanceamento de pesos para mitigar o viés da classe majoritária.
- XGBoost (Extreme Gradient Boosting):** Utilizado com o parâmetro ``scale_pos_weight=10`` para penalizar erros na classe minoritária, apresentando alto desempenho preditivo.
- Otimização de Hiperparâmetros e Limiar de Decisão:** Utilização de ``GridSearchCV`` focando na métrica *Recall* (essencial para minimizar fraudes não detectadas) e ajuste customizado do limiar de decisão (``*threshold*``) para ``0.3``, calibrando o compromisso entre precisão e sensibilidade.

Destaque Arquitetural: A implementação de pipelines estruturados com o Scikit-Learn garantiu a reprodutibilidade e prevenção de vazamento de dados (*data leakage*) durante o processo de escalonamento.

4. Explicabilidade do Modelo (SHAP)

Em ambientes regulados e corporativos, a acurácia isolada é insuficiente. O projeto integrou a biblioteca **SHAP** (**Shapley Additive exPlanations**) para decodificar o comportamento do modelo XGBoost. A análise SHAP permitiu mensurar visualmente quais variáveis exercem maior impacto nas decisões de classificação de risco, garantindo transparência analítica e interpretabilidade para auditores e equipes de segurança.

5. Conclusão e Avaliação Técnica

O projeto demonstra domínio técnico sobre problemas de classificação altamente desbalanceados e engenharia de machine learning. Na avaliação de desempenho e aplicabilidade em cenários reais, a combinação do algoritmo **XGBoost** com a explicabilidade via **SHAP** destacou-se como a abordagem ideal, unindo a capacidade preditiva superior de modelos de reforço de gradiente com a transparência indispensável para o setor financeiro.